




Chimica Analitica Magistrale

Docente

Andreas Stephan Lesch

Appunti di lezione

Redattore:

Alessandro Suprani

alessandro.suprani@studio.unibo.it

Laurea Magistrale in Chimica Industriale

Anno Accademico 2024/2025

Indice

I	Statistica	2
1	Le basi della statistica	2
1.1	Popolazione e campione, normalità	2
1.1.1	Popolazione e campione	2
1.1.2	Normalità	2
1.2	Media e Deviazione Standard	2
1.2.1	Media	2
1.2.2	Normalità	3
1.3	La distribuzione di Laplace-Gauss	3
1.3.1	La variabile ridotta	4
1.4	Teorema del limite centrale (CLT)	4
1.5	La legge di Student	5
1.6	Test di significatività	6
1.6.1	Test di accuratezza (Test t)	6
1.6.2	Test di precisione (Test F)	7
2	ANalysis Of VAriance (ANOVA)	7
2.1	ANOVA a una via	7
2.2	Test di Fisher	9
2.3	Anova a due vie	9
3	Test Post Hoc	10
3.1	Test di Tukey	10
3.2	Test di Tukey-Kramer	11
4	Design of Experiment (DOE)	11
4.1	Design Of Experiment (DOE)	11

Parte I

Statistica

1 Le basi della statistica

1.1 Popolazione e campione, normalità

1.1.1 Popolazione e campione

Nella statistica, i termini **popolazione** e **campione** fanno riferimento a concetti ben distinti:

- **Popolazione:** l'insieme di tutte le possibili osservazioni rilevabili.
- **Campione:** una porzione della popolazione selezionata per l'analisi.

1.1.2 Normalità

Dopo aver selezionato il campione, è necessario verificarne la normalità, ossia stabilire se i dati seguono una distribuzione normale (la "Campana di Gauss"). Se i dati sono normalizzati, è possibile applicare direttamente i test statistici. In caso contrario, si può applicare il teorema del limite centrale per trattare il campione come distribuito normalmente.




Figura 1: Diagramma di flusso per la gestione dei dati

1.2 Media e Deviazione Standard

1.2.1 Media

La media ($\bar{x}$ o μ) si utilizza per variabili a intervallo (con zero arbitrario, come la temperatura in °C) o a rapporto (zero assoluto, come la temperatura in K). Ed è calcolata:

$$\mu = \frac{\sum_{i=1}^n x_i}{n}$$

1.2.2 Normalità

Tuttavia, la media **non** è sufficiente a descrivere un campione in modo completo, perché campioni diversi possono avere la stessa media ma una dispersione di dati completamente diversa, come riportato in **Figura 2**.




Figura 2: Esempi di come possono presentarsi i dati

Perciò, si calcola la **varianza della popolazione** (σ^2), che misura la dispersione dei dati rispetto alla media:

$$\sigma^2 = \frac{\sum_{i=1}^N (x_i - \mu)^2}{N}$$

Per ripristinare le unità originali, si calcola la **deviazione standard della popolazione** (σ):

$$\sigma = \sqrt{\frac{\sum_{i=1}^N (x_i - \mu)^2}{N}}$$

Varianza e deviazione standard del campione sono indicate rispettivamente con s^2 e s , ma seguono lo stesso principio.

$$s^2 = \frac{\sum_{i=1}^N (x_i - \bar{x})^2}{N}$$

Varianza del Campione

$$s = \sqrt{\frac{\sum_{i=1}^N (x_i - \bar{x})^2}{N}}$$

Deviazione Standard del Campione

1.3 La distribuzione di Laplace-Gauss

Quando molteplici fattori indipendenti influenzano una misurazione, il risultato segue una distribuzione normale, detta anche **Campana di Gauss**. L'ampiezza della campana riflette la variabilità delle misure nel campione.

$$y = \frac{e^{-\frac{(x-\mu)^2}{2\sigma^2}}}{\sigma\sqrt{2\pi}}$$

Proprietà delle distribuzioni gaussiane è che l'area compresa nello stesso intervallo $\pm\sigma$ intorno alla media μ rappresenta la stessa percentuale dell'area totale.




Figura 3: Distribuzione secondo la campana di Gauss

1.3.1 La variabile ridotta

Nasce la necessità di normalizzare il valore di $\mu \pm \sigma$ per poter confrontare le distribuzioni e quindi si introduce la **variabile ridotta z**:

$$z = \frac{x - \mu}{\sigma}$$

La variabile ridotta presenta media pari a 0 e deviazione std uguale a 1.




Figura 4: Effetto dell'introduzione della variabile ridotta z (notare il cambio di assi)

E' importante avere i dati distribuiti normalmente in quanto nell'intervallo di deviazione $\pm\sigma$ dal valore atteso è possibile trovare il 68,27% di tutti i valori, valore che cresce a 95,45% se l'intervallo di deviazione sale a $\pm 2\sigma$.




Figura 5: Rappresentazione grafica degli intervalli di deviazione

1.4 Teorema del limite centrale (CLT)

Il teorema del limite centrale afferma che la somma di n variabili indipendenti aventi identica distribuzione è una variabile che si distribuisce normalmente qualsiasi sia la tipologia di distribuzione di partenza. Se si prendono tutti i possibili campioni, ognuno di dimensione n, da qualsiasi popolazione di media μ e deviazione standard σ , la distribuzione delle medie dei campioni avrà media uguale alla media della popolazione, varianza pari a $\frac{\sigma^2}{n}$ e la deviazione standard delle medie (definito **ERRORE STANDARD**) risulterà essere $\frac{\sigma}{\sqrt{n}}$ che sarà distribuita normalmente se lo era la distribuzione di origine oppure tenderà ad essere normale per numero grande di campioni come mostrato in **Figura 6**.

- La deviazione standard è una misura della **variabilità dei dati** e rimane costante all'aumentare di n
- L'errore standard misura la **precisione della media campionaria** e diminuisce all'aumentare di n





Figura 6: Distribuzione della media delle medie campionarie



Confidenza

Dato che il valore medio $\bar{x}$ è una stima del valore vero μ , abbiamo bisogno di definire un intervallo all'interno del quali si possa assumere che giaccia il valore vero: l'intervallo di confidenza.

$$\bar{x} - z \left(\frac{\sigma}{\sqrt{n}} \right) < \mu < \bar{x} + z \left(\frac{\sigma}{\sqrt{n}} \right)$$

1.5 La legge di Student

$$\mu = \bar{x} \pm t \left(\frac{s}{\sqrt{n}} \right)$$

Questa legge sostituisce la legge normale quando la deviazione standard è una stima campionaria.

Il valore t è un valore tabulato che dipende dal numero di gradi di libertà (df) e dall'intervallo di confidenza (ci) scelto. La distribuzione t viene utilizzata quando n è piccolo (<30) e σ è sconosciuto. Il termine t è utilizzato per applicare i test di significatività alle basi di dati ottenute.




Figura 7: Differenza apportata dai gradi di libertà alla curva descritta.

1.6 Test di significatività

Nell'analisi delle misure sperimentali, è essenziale utilizzare test di significatività per valutare se vi siano differenze significative tra i risultati ottenuti. Questi test si fondano sulla formulazione di un'ipotesi nulla (H_0), la quale viene accettata o rifiutata in base ai dati raccolti. In alternativa, si prende in considerazione un'ipotesi alternativa (H_a o H_1), che rappresenta la negazione dell'ipotesi nulla.

Un metodo di stima è considerato "robusto" quando dimostra una bassa sensibilità a leggere deviazioni dalle ipotesi di base del modello, come piccoli scostamenti dalla distribuzione normale. Generalmente, un test respinge l'ipotesi nulla (assenza di differenza) quando la probabilità che tale differenza si verifichi per caso è inferiore al 5% ($P < 0,05$). In tal caso, la differenza viene considerata significativa, con una probabilità del 95% ($P = 0,95$), corrispondente a $1 - \alpha = 1 - 0,05$.

Tuttavia, se l'ipotesi nulla non viene rifiutata, ciò non dimostra necessariamente che sia vera (bensì che non è stata falsificata), poiché esistono due tipi di errori:

- Errore di prima specie (falso positivo): rifiutare H_0 quando essa è vera.
- Errore di seconda specie (falso negativo): accettare H_0 quando essa è falsa.

1.6.1 Test di accuratezza (Test t)

Confronto media - valore noto

Questo è un test a una coda che risponde alla domanda: "Il campione di dimensione n , con media $\bar{x}$ e varianza s^2 , può considerarsi appartenente a una popolazione con media μ ?"

H_0 : non ci sono differenze significative tra i due valori.

H_1 : ci sono differenze significative tra i due valori.

Si calcola il valore di t :

$$t_{\text{calc}} = \left| \frac{\bar{x} - \mu}{\frac{s}{\sqrt{n}}} \right|$$

e si confronta con il valore critico t_{crit} (tabulato), corrispondente ai gradi di libertà ($n - 1$).

Se $t_{\text{calc}} > t_{\text{crit}}$, allora H_0 viene rigettata.

Confronto media - media

Questo è un test a due code che risponde alla domanda: "I due campioni, di dimensioni n_1 e n_2 , con medie $\bar{x}_1$ e $\bar{x}_2$ e varianze s_1^2 e s_2^2 , possono considerarsi appartenenti a una popolazione con la stessa media?"

H_0 : non ci sono differenze significative tra le due medie.

H_1 : ci sono differenze significative tra le due medie.

Se s_1^2 e s_2^2 sono **omoschedastiche** (ovvero hanno la stessa varianza), possiamo calcolare la varianza combinata come:

$$s^2 = \frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}$$

e quindi calcolare:

$$t_{\text{calc}} = \frac{|\bar{x}_1 - \bar{x}_2|}{\sqrt{s^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}}$$

Se $t_{\text{calc}} > t_{\text{crit}}$, allora H_0 viene rigettata.

Test t per valori accoppiati

Quando lo stesso dato è ottenuto utilizzando due metodi diversi, si rende necessario adattare il test t. Si procede calcolando la differenza d tra ciascuna coppia di risultati:

$$d_{\text{coppia}} = y_{\text{Serie1}} - y_{\text{Serie2}}$$

e successivamente calcolando la media delle differenze:

$$d_{\text{med}} = \frac{\sum d_{\text{coppia}}}{n}$$

dove n è il numero di coppie. Da qui è possibile eseguire un test t, calcolando:

$$t_{\text{calc}} = \left| \frac{d_{\text{med}}}{\frac{s_d}{\sqrt{n}}} \right|$$

La H_0 afferma che non ci sono differenze significative tra le popolazioni dei due campioni, e viene rigettata se $t_{\text{calc}} > t_{\text{crit}}$.

1.6.2 Test di precisione (Test F)

Il test F confronta il rapporto tra due varianze per verificare se le due popolazioni siano normali e abbiano varianze identiche (H_0). Il valore di F è calcolato come:

$$F_{\text{calc}} = \frac{s_1^2}{s_2^2}$$

con $F > 1$.

Se $F_{\text{calc}} > F_{\text{crit}}$, allora H_0 viene rigettata.

2 ANALYSIS OF VARIANCE (ANOVA)

L'ANOVA è una tecnica statistica utilizzata per confrontare tra loro due o più medie o per valutare l'effetto di uno o più fattori di variazione sulle medie e stimarne gli effetti. È impiegata per confrontare le medie di tre o più gruppi e determinare se almeno uno di essi è significativamente diverso dagli altri. Questa tecnica risulta particolarmente utile quando si vogliono analizzare variabili categoriali (fattori) rispetto a una variabile continua (risposta).

2.1 ANOVA a una via

L'ANOVA a una via consente di valutare se vi sia una differenza significativa tra le medie di più di due campioni. Durante un'ANOVA, esistono due principali fonti di variazione:

- Errori casuali nella misurazione: intrinseci nell'esecuzione delle misure, dovuti alla casualità dei processi di misura.
- Fattori controllati: processi di produzione, metodi analitici, analisti coinvolti, indicati come gruppi.

L'ANOVA è in grado di separare la variazione dovuta ai fattori controllati da quella dovuta alla casualità. Per ottenere risultati affidabili, l'ANOVA richiede almeno tre medie da confrontare.

L'ipotesi nulla H_0 afferma che il fattore controllato non ha alcuna influenza sui risultati delle prove, il che implica che i gruppi appartengano alla stessa popolazione (stessa distribuzione stocastica). L'ipotesi alternativa, H_1 , suggerisce che almeno uno dei gruppi abbia una media significativamente diversa dagli altri.

Per verificare H_0 , si calcola la **devianza totale**, espressa come:

$$SS_{\text{totale}} = \sum_{i=1}^n (x_i - \mu)^2$$

dove μ è la media generale dei dati.

I gradi di libertà sono calcolati come:

$$df_{\text{tot}} = n_{\text{repliche totali}} - 1$$

Ora è necessario calcolare la devianza **entro** i gruppi e **tra** i gruppi.

Devianza entro i gruppi

La devianza entro i gruppi riflette la variazione tra le repliche di ciascun esperimento all'interno dello stesso gruppo. È calcolata come:

$$SS_{A,\text{mr}} = \sum_{i=1}^n (x_i - \mu_A)^2$$

$$SS_{B,\text{mr}} = \sum_{i=1}^n (x_i - \mu_B)^2$$

La devianza complessiva all'interno dei gruppi è data da:

$$SS_{\text{entro i gruppi}} = SS_{A,\text{mr}} + SS_{B,\text{mr}}$$

I gradi di libertà relativi alla devianza entro i gruppi sono:

$$df_{\text{entro}} = h(n - 1)$$

dove h è il numero di gruppi e n è il numero di repliche.

Devianza tra i gruppi

La devianza tra i gruppi rappresenta la variazione tra le medie dei diversi gruppi. Per calcolarla, si separa la variazione tra le prove da quella interna ai gruppi, basandosi sull'assunzione che ogni risultato all'interno di un gruppo sia pari alla media dei risultati ottenuti nello stesso gruppo. Si calcola come segue:

$$SS_A = (\mu_A - \mu_{\text{gen}})^2 \times N_A$$

$$SS_B = (\mu_B - \mu_{\text{gen}})^2 \times N_B$$

dove μ_{gen} è la media generale, mentre N_A e N_B sono rispettivamente le dimensioni dei gruppi A e B .

La devianza tra i gruppi è quindi:

$$SS_{\text{tra i gruppi}} = SS_A + SS_B$$

I gradi di libertà per la devianza tra i gruppi sono calcolati come:

$$df_{\text{tra}} = h - 1$$

Devianza totale

$$SS_{Totale} = SS_{entrogruppi} + SS_{traigruppi}$$

L'ANOVA può essere anche automatizzato

		Devianza	Gradi di libertà	Varianza
		SS	GL	VAR
"trattamento" (fra i gruppi) FATTORE CONTROLLATO	trat	24	1	24
"errore" (entro i gruppi) FATTORE NON CONTROLLATO	res	10	4	2.5
	TOTALE	34	5	

Somme

2.2 Test di Fisher

Il test di Fisher per l'ANOVA frapponne le varianze precedentemente calcolate:

$$F_{calc} = \frac{VAR_{fraigruppi}}{VAR_{entrogruppi}}$$

Si sceglie il livello α di significatività del test e si individua il valore di F_{tab} ad una coda nelle tavole per probabilità $P = 0,95$ corrispondente ai gradi di libertà, considerando che **i df tra i gruppi sono in orizzontale mentre quelli entro i gruppi sono in verticale**.

Se $F_{calc} > F_{tab}$ l'ipotesi nulla è respinta (almeno un gruppo non appartiene all'origine degli altri)

2.3 ANOVA a Due Vie

L'analisi della varianza a due vie (ANOVA a due vie) consente di esaminare l'effetto di più fattori controllati simultaneamente. Questa metodologia è utile per verificare se i fattori influenzano i risultati in modo indipendente o se vi è un'interazione tra di essi.

La matrice utilizzata per l'analisi è composta da gruppi e blocchi:

- I **gruppi** (o trattamenti) rappresentano il fattore controllato A.
- I **blocchi** rappresentano il fattore controllato B.

In questo contesto, vengono inserite direttamente le medie di ciascuna serie di ripetizioni.

Impostiamo le ipotesi statistiche:

- **Ipotesi nulla** (H_0): I fattori controllati non hanno alcuna influenza sui risultati delle prove.
- **Ipotesi alternativa** (H_1): I fattori controllati esercitano un'influenza significativa sui risultati delle prove, ovvero esiste almeno un caso in cui $\mu_i \neq \mu_j$.

Il concetto è simile a quello dell'ANOVA a una via, in quanto si calcolano le varianze e si confrontano mediante il test di Fisher per determinare se ci sono differenze significative. Pertanto, è necessario calcolare le varianze tra i trattamenti, tra i blocchi e l'errore sperimentale. La devianza totale (somma dei quadrati) è data dalla seguente relazione:

$$SS_{tot} = SS_{trat} + SS_{bloc} + SS_{res}$$

La devianza dell'errore sperimentale può essere calcolata agevolmente per differenza. I passaggi per il calcolo sono i seguenti:

1. Calcolare la devianza totale SS_{tot} utilizzando il consueto metodo $(\bar{x} - \mu)^2$ per ogni valore nella matrice. I gradi di libertà (DOF) sono $n - 1$.
2. Calcolare la devianza tra i gruppi/trattamenti: determinare la differenza al quadrato tra ogni media dei trattamenti e la media generale, moltiplicando poi per il numero di blocchi. I gradi di libertà sono il numero di trattamenti meno 1.
3. Calcolare la devianza tra i blocchi: applicare lo stesso procedimento del calcolo della devianza per i trattamenti, invertendo l'approccio. I gradi di libertà sono il numero di blocchi meno 1.
4. La devianza residua è calcolata come segue: $SS_{res} = SS_{tot} - SS_{bloc} - SS_{trat}$.

Infine, si esegue il test di Fisher, calcolando:

$$F_{trat} = \frac{Var_{trat}}{Var_{res}} \quad \text{e} \quad F_{bloc} = \frac{Var_{bloc}}{Var_{res}}$$

Se $F_{calc} > F_{tab}$, l'ipotesi nulla H_0 viene rigettata.

3 Test Post Hoc

Il test post hoc viene eseguito dopo l'ANOVA quando si riscontra una differenza significativa tra le medie, ovvero quando l'ipotesi nulla è stata rifiutata. Supponiamo di avere k trattamenti e n_i osservazioni per ogni trattamento.

Se il numero di osservazioni per ciascun trattamento è uguale, si utilizza il **test di Tukey**. Nel caso in cui il numero di osservazioni differisca tra i trattamenti, si applica il **test di Tukey-Kramer**.

3.1 Test di Tukey

Prima alternativa: Q

Per ogni coppia di medie x e y , si calcola un parametro Q_{calc} secondo la formula:

$$Q_{calc} = \frac{|\bar{x}_x - \bar{x}_y|}{\sqrt{\frac{Var_{Res}}{n_i}}}$$

dove $\bar{x}_x$ e $\bar{x}_y$ rappresentano le medie dei trattamenti x e y , rispettivamente, e Var_{Res} è la varianza residua.

Le differenze tra le medie sono considerate statisticamente significative se il valore di Q_{calc} supera il parametro critico Q_{crit} , ottenuto da apposite tabelle in funzione del livello di confidenza scelto α , del numero k di medie a confronto, e dei gradi di libertà associati alla varianza residua entro i gruppi (Var_{Res}) dell'ANOVA.

Il test di Tukey confronta tutte le possibili coppie di medie, identificando quali differenze superano il valore critico Q_{crit} e risultano, quindi, significative.

Seconda alternativa: W

Si calcola la differenza delle medie per ogni coppia di medie:

$$|\bar{x}_x - \bar{x}_y|$$

e si confronta con l'intervallo minimo significativo W :

$$W = Q_{crit} \sqrt{\frac{Var_{res}}{n_i}}$$

3.2 Test di Tukey-Kramer

Nel test di Tukey-Kramer, si utilizza una media armonica n' :

$$n' = \frac{k}{\frac{1}{n_1} + \frac{1}{n_2} + \dots + \frac{1}{n_n}}$$

Si usa n' al posto di n_i per calcolare l'intervallo minimo significativo:

$$W = Q_{\text{crit}} \sqrt{\frac{Var_{\text{res}}}{n'}}$$

e lo si paragona alla differenza delle medie per ogni coppia di medie

4 Design of Experiment (DOE)

Supponiamo di voler ottimizzare due variabili. Un approccio semplice consiste nel modificare un fattore mantenendo fisso l'altro.

Un fattore alla volta

In questo metodo, si mantiene fisso un fattore (ad esempio, il tempo fissato a 20 ore) mentre si varia l'altro. Questo approccio è però lento e poco efficiente in termini di tempo, un aspetto particolarmente rilevante in ambito aziendale.

4.1 Design Of Experiment (DOE)

Un metodo più efficace per la sperimentazione è rappresentato dall'utilizzo di esperimenti progettati statisticamente. In questo caso, si crea una regione sperimentale definendo degli estremi significativamente differenti per i fattori da analizzare.

Con due fattori da valutare contemporaneamente, ognuno con due livelli (alto e basso), si ottengono $2 \times 2 = 4$ prove. Questa configurazione è nota come "due fattori a due livelli".

Le condizioni per operare con un design sperimentale includono:

- Definizione chiara dei fattori che influenzano i risultati dell'esperimento.
- Pianificazione degli esperimenti in modo da minimizzare l'effetto di fattori incontrollati.




Figura 8: Regione sperimentale scelta e punti individuati

Il numero di prove per questi disegni è dato da 2^k , dove 2 rappresenta il livello (alto o basso) e k è il numero di fattori. Ogni prova è definita attraverso una metodologia specifica.

Prova		Trattamento/ combinazione	
Run	comb	Fattori coded	
		a	b
1	1	-	-
2	a	+	-
3	b	-	+
4	ab	+	+

I fattori vengono codificati con + e - (rispettivamente limite superiore e inferiore). Assegnando *a* e *b* ai fattori, le combinazioni sono indicate dal limite superiore: *a* se il fattore *a* è superiore, *b* se il fattore *b* è superiore, *ab* se entrambi sono superiori, e 1 quando entrambi sono inferiori.

Strutturando in questo modo gli esperimenti otteniamo che i due fattori sono ortogonali, cioè che stimiamo l'effetto del fattore senza che esso venga distorto dal fattore *b*. Si dice che due fattori sono ortogonali se, nello spazio degli esperimenti, ogni livello di un fattore è associato lo stesso numero di volte con ogni livello dell'altro.